

INFORME TÉCNICO

Implementación de un Modelo de Machine Learning para el Mantenimiento Predictivo de Equipos Industriales

Autor: Aldo Fuentes Zaldivar

Asesor: Jorge Marcos Medina Sánchez

Institución: Universidad Autónoma del Estado de México

Carrera: ingeniería mecánica

Materia: Informes Técnicos en Ingeniería

Toluca, Estado de México — 2025–2026

Dataset: AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020)

Abstract

This technical report presents the design, implementation and evaluation of a Machine Learning (ML) model for predictive maintenance of industrial equipment, based on the AI4I 2020 Predictive Maintenance Dataset from the UCI Machine Learning Repository (Matzka, 2020). The study applies the CRISP-DM methodology (Wirth & Hipp, 2000) across six structured phases: business understanding, data understanding, data preparation, modeling, evaluation, and deployment. Three supervised classification algorithms were compared — Decision Tree, Random Forest, and Logistic Regression — trained on 10,000 operational records containing air temperature (295.60–304.40 K), process temperature (306.10–313.70 K), rotational speed (1,181–2,886 rpm), torque (3.80–76.60 Nm), and tool wear (0–253 min). Class imbalance (96.61% normal / 3.39% failure) was addressed through SMOTE oversampling. The Random Forest classifier achieved the best performance: Recall = 0.8824, F1-Score = 0.5063, and AUC-ROC = 0.9710, confirming that the model detects 88.24% of real failures when risk thresholds are reached: torque > 45.95 Nm, rotational speed < 1,421.50 rpm, and tool wear > 84.50 min. The hypothesis — that a ML model trained on these operational intervals would achieve Recall ≥ 0.80 — was not falsified under Popper's falsificationist criterion (Coutiño, 2011), validating the technical viability of predictive maintenance as an alternative to reactive maintenance schemes in industrial settings.

Keywords: predictive maintenance, machine learning, Random Forest, CRISP-DM, AI4I 2020, supervised classification, SMOTE, industrial equipment failure.

Resumen

El presente informe técnico documenta el diseño, implementación y evaluación de un modelo de Machine Learning (ML) para el mantenimiento predictivo de equipos industriales, empleando el AI4I 2020 Predictive Maintenance Dataset del repositorio UCI Machine Learning Repository (Matzka, 2020). El estudio aplica la metodología CRISP-DM (Wirth & Hipp, 2000) en seis fases estructuradas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y

despliegue. Se compararon tres algoritmos de clasificación supervisada — Árbol de Decisión, Bosque Aleatorio y Regresión Logística — entrenados sobre 10,000 registros operativos que incluyen temperatura del aire (295.60–304.40 K), temperatura de proceso (306.10–313.70 K), velocidad de rotación (1,181–2,886 rpm), torque (3.80–76.60 Nm) y desgaste de herramienta (0–253 min). El desbalance de clases (96.61% normal / 3.39% falla) fue compensado mediante la técnica SMOTE. El clasificador Bosque Aleatorio obtuvo el mejor desempeño: Recall = 0.8824, F1-Score = 0.5063 y AUC-ROC = 0.9710, confirmando que el modelo detecta el 88.24% de las fallas reales cuando se alcanzan los umbrales de riesgo: torque > 45.95 Nm, velocidad < 1,421.50 rpm y desgaste > 84.50 min. La hipótesis de solución — que un modelo de ML entrenado con dichos intervalos operativos alcanzaría un Recall ≥ 0.80 — no fue falsada bajo el criterio falsacionista de Popper (Coutiño, 2011), validando la viabilidad técnica del mantenimiento predictivo como alternativa al esquema reactivo.

Palabras clave: mantenimiento predictivo, machine learning, Bosque Aleatorio, CRISP-DM, AI4I 2020, clasificación supervisada, SMOTE, falla de equipo industrial.

Contents

Abstract.....	1
Resumen.....	1
1. Planteamiento del problema 	1
1.1. Contextualización: Tiempo, Lugar y Relación con el Autor	1
1.2. Descripción del Fenómeno y los Procesos Actuales	1
1.3. La Tecnología Propuesta: IA y Machine Learning	1
1.4. Factibilidad y Análisis Costo–Beneficio.....	2
1.5. Hipótesis de Solución	2
1.5.1. Hipótesis Específicas por Modo de Falla (H1–H4)	3
1.6. Pregunta de investigación.....	3
2. Objetivos 	4
2.1. Objetivo General (Nivel Bloom: Crear — Nivel 6)	4
2.2. Objetivos Específicos	4
2.2.1. OE1 — Recordar / Comprender (Nivel 1–2)	4
2.2.2. OE2 — Aplicar / Analizar (Nivel 3–4)	4
2.2.3. OE3 — Evaluar / Crear (Nivel 5–6)	5
3. Marco Teórico	5
3.1. Teorías que Justifican la Solución (Falsacionismo de Popper)	5
3.1.1. Teoría 1: El Aprendizaje Supervisado como Mecanismo de Clasificación de Fallas en Equipos Industriales	5
3.1.2. Teoría 2: La Degradación de Equipos Industriales es un Proceso Detectable y Predecible mediante Señales Operativas.....	6
3.1.3. Teoría 3: El Proceso Estándar CRISP-DM Garantiza la Reproducibilidad y Validez Científica de los Proyectos de Machine Learning	8
3.1.4. Síntesis: Coherencia Teórica bajo el Falsacionismo de Popper	9
3.2. Método Científico de Bunge — Pasos Aplicados al Proyecto	10
4. Datos de Prueba y Gráficas (Fase de prueba)	15
4.1. Figuras del Análisis Estadístico	15

5. Entrenamiento y Evaluación del Modelo de Machine Learning (Fase de prueba)	18
5.1. — Preparación de Datos	19
5.2. — Entrenamiento de Modelos	20
5.2.1. Árbol de Decisión (Decision Tree Classifier)	20
5.2.2. Bosque Aleatorio (Random Forest Classifier)	21
5.2.3. Regresión Logística (Logistic Regression)	21
5.2.4. Validación Cruzada	21
5.2.5. — Resultados de Evaluación	21
5.2.6. — Métricas por Clase — Normal y Falla	22
6. Análisis e Interpretación de Resultados	26
6.1. Selección del Modelo: Bosque Aleatorio y verificación de la Hipótesis de Solución (Conclusión)	26
6.1.1. Sobre el Precision-Recall Trade-off (Hallazgos o Recomendaciones)	26
6.1.2. Importancia de Variables (Hallazgos o Recomendaciones)	27
7. Aplicación del Framework CRISP-DM	27
8. Referencias (APA 7)	28
Anexos	31
Anexo A — Script Python: Análisis Estadístico y Generación de Figuras 1–6	31
Anexo B — Script Python: Entrenamiento y Evaluación del Modelo ML	31
Anexo C — Tabla de Intervalos por Modo de Falla	31
Anexo D — Tabla de Dependencias del Proyecto	32
Anexo E — Descripción del Dataset AI4I 2020	33

1. Planteamiento del problema

1.1. Contextualización: Tiempo, Lugar y Relación con el Autor

El presente informe técnico corresponde a un proyecto de desarrollo personal realizado por el autor durante el periodo 2025–2026, en el marco de su formación como estudiante de los últimos semestres de ingeniería mecánica en Universidad Autónoma del Estado de México, con sede en Toluca, Estado de México. El área de estudio se delimita al análisis de datos operativos de equipos industriales — temperatura, velocidad de rotación, torque y desgaste de herramientas— cuyo comportamiento anómalo puede anticiparse mediante modelos de clasificación supervisada (Matzka, 2020).

1.2. Descripción del Fenómeno y los Procesos Actuales

En entornos industriales de prueba y validación, los equipos especializados operan bajo ciclos continuos de alta exigencia. El mantenimiento reactivo predominante cuesta entre 3 y 5 veces más que el preventivo, una vez contabilizado el daño acumulado por tiempo de inactividad (Siemens, 2024). Una falla de emergencia puede costar hasta 40 veces más que la misma reparación planificada (Vista Projects, 2026).

1.3. La Tecnología Propuesta: IA y Machine Learning

Con la disponibilidad de datos de monitoreo de condición — velocidad de rotación, temperatura, torque, desgaste de herramientas, vibración, presión, voltaje y otros parámetros eléctricos y mecánicos — hoy es posible prevenir fallas potenciales y estimar la vida útil restante de los equipos mediante modelos matemáticos avanzados (Machine Learning) (Carvalho et al., 2021). La metodología de implementación de referencia es CRISP-DM, que estructura el proyecto en seis fases reproducibles (Wirth & Hipp, 2000).

1.4. Factibilidad y Análisis Costo–Beneficio

Hakunamatata Tech (2025) reporta que las organizaciones que implementan mantenimiento predictivo logran una eliminación del 70 al 75% de las fallas de equipos, reducción de costos de mantenimiento del 18 al 31%, e incremento de productividad del 25% Hakunamatatatech. En cuanto a retorno de inversión, el Departamento de Energía de los Estados Unidos indica que el mantenimiento predictivo entrega en promedio un ROI de 10:1, equivalente a un retorno del 1,000% sobre la inversión del programa (Oxmaint, 2026). Desde el punto de vista de factibilidad del proyecto personal, la solución presenta costo de implementación prácticamente nulo: el dataset es público y gratuito (Matzka, 2020), el desarrollo se realiza en Python con librerías de código abierto, y no se requiere infraestructura adicional.

Concepto	Mantenimiento Reactivo	Mantenimiento Predictivo con ML
Intervención	Después de la falla	Antes de la falla
Costo de reparación	Alto (falla total)	Bajo (intervención temprana)
Tiempo muerto	Impredecible	Planificado y reducido
Costo de datos		\$0 (dataset público UCI)
Costo de desarrollo		\$0 (Python + librerías open source)

1.5. Hipótesis de Solución

Si las señales operativas del equipo industrial presentan una temperatura del aire superior a 299.10 K, una velocidad de rotación inferior a 1,421.50 rpm, un torque superior a 45.95 Nm y un desgaste de herramienta acumulado mayor a 84.50 minutos —intervalos correspondientes al primer cuartil (Q1) de la distribución en condición de falla observada en el AI4I 2020 Dataset (Matzka, 2020)— entonces la probabilidad de falla del equipo supera el umbral crítico, y un modelo de Machine Learning entrenado con dichos intervalos será capaz de anticipar la falla con Recall ≥ 0.80 .

1.5.1. Hipótesis Específicas por Modo de Falla (H1–H4)

Modo	Nombre	Condición de Falla (intervalos reales)	Hipótesis Específica
TWF	Desgaste de Herramienta	Desgaste ≥ 198 min ($\mu=216.4$ min, $\text{máx}=253$ min)	Si el desgaste acumulado supera los 198 min, el equipo presentará falla por desgaste independientemente de temperatura y torque.
HDF	Disipación de Calor	Diff. térmica 7.60–8.60 K + vel. 1,212–1,379 rpm + torque 41.60–68.20 Nm	Si la diferencia térmica proceso-aire cae bajo 8.6 K con vel. $< 1,379$ rpm, el equipo fallará por disipación insuficiente.
PWF	Exceso de Potencia	Potencia $< 3,500$ W o $> 9,000$ W (torque 3.80–76.60 Nm, vel. 1,200–2,886 rpm)	Si la potencia cae fuera del rango 3,500–9,000 W, el equipo presentará falla por exceso o deficiencia de potencia.
OSF	Sobrecarga	Torque ≥ 46.30 Nm ($\mu=58.37$) + Desgaste ≥ 172 min ($\mu=207.7$ min)	Si torque ≥ 46.30 Nm y desgaste ≥ 172 min ocurren simultáneamente, el equipo presentará falla por sobrecarga.
RNF	Falla Aleatoria	Vel. 1,306–1,687 rpm, torque 27.70–61.20 Nm ($n=19$, naturaleza estocástica)	La falla aleatoria no presenta patrón determinístico; el modelo la tratará como ruido en la clase de falla.

Nota. Intervalos calculados del AI4I 2020 Dataset (Matzka, 2020). Las hipótesis H1–H4 son falsables: si el modelo no detecta la falla cuando se cumplen las condiciones, la hipótesis queda refutada (Coutiño, 2011). Elaboración propia.

1.6. Pregunta de investigación

¿Puede un modelo de Machine Learning, entrenado con señales operativas del AI4I 2020 Dataset (Matzka, 2020), clasificar correctamente como falla las observaciones donde la temperatura del aire supera los 299.10 K, la velocidad de rotación cae por debajo de 1,421.50 rpm, el torque excede los 45.95 Nm y el desgaste acumula más de 84.50 minutos, alcanzando un Recall ≥ 0.80 ?

2. Objetivos

2.1. Objetivo General (Nivel Bloom: Crear — Nivel 6)

✓ Desarrollar un modelo de Machine Learning para la clasificación y predicción de fallas en equipos industriales, mediante el análisis y procesamiento del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020), con la finalidad de demostrar que el modelo es capaz de detectar condiciones de riesgo —torque > 45.95 Nm, velocidad $< 1,421.50$ rpm, desgaste > 84.50 min— con un Recall ≥ 0.80 , validando la viabilidad técnica del mantenimiento predictivo.

2.2. Objetivos Específicos

2.2.1. OE1 — Recordar / Comprender (Nivel 1–2)

✓ Identificar los intervalos operativos críticos de las cinco variables del AI4I 2020 Dataset —temperatura del aire (295.60–304.40 K en falla), temperatura de proceso (306.10–313.70 K en falla), velocidad de rotación (Q1 falla = 1,326.50 rpm), torque (Q1 falla = 45.95 Nm) y desgaste de herramienta (Q1 falla = 84.50 min)— mediante exploración estadística descriptiva con Python 3.12.3, con el fin de delimitar las zonas de riesgo para cada uno de los cinco modos de falla: TWF, HDF, PWF, OSF y RNF (Matzka, 2020).

2.2.2. OE2 — Aplicar / Analizar (Nivel 3–4)

✓ Analizar los patrones de comportamiento estadístico asociados a cada modo de falla —TWF (desgaste ≥ 198 min), HDF (diferencia térmica ≤ 8.6 K con vel. 1,212–1,379 rpm), PWF (potencia fuera de 3,500–9,000 W), OSF (torque ≥ 46.30 Nm y desgaste ≥ 172 min)— mediante técnicas de visualización y análisis con las librerías pandas 3.0.2 y matplotlib 3.10.8 de Python, con la finalidad de confirmar estadísticamente ($p < 0.001$) la separabilidad de las zonas de riesgo y preparar los datos para el entrenamiento del modelo (Carvalho et al., 2021).

2.2.3. OE3 — Evaluar / Crear (Nivel 5–6)

✓ Evaluar la efectividad del modelo de clasificación desarrollado mediante indicadores de desempeño —Recall ≥ 0.80 como criterio mínimo de éxito establecido en la hipótesis, complementado con F1-Score y AUC-ROC— que midan su capacidad para identificar correctamente las condiciones de falla definidas por los intervalos operativos críticos, con el propósito de determinar la viabilidad técnica del modelo como herramienta de mantenimiento predictivo (Fawcett, 2006; Matzka, 2020).

3. Marco Teórico

3.1. Teorías que Justifican la Solución (Falsacionismo de Popper)

Bajo la metodología de Karl Popper, toda teoría científica válida debe ser falsable (Coutiño, 2011). Las tres teorías presentadas sustentan la solución desde ángulos complementarios y ninguna ha sido falsada en condiciones análogas al presente proyecto.

3.1.1. Teoría 1: El Aprendizaje Supervisado como Mecanismo de Clasificación de Fallas en Equipos Industriales

Conjetura (Planteamiento teórico)

La primera teoría que sustenta este proyecto establece que los algoritmos de aprendizaje supervisado son capaces de aprender patrones de falla a partir de datos históricos etiquetados y generalizar ese aprendizaje para clasificar correctamente nuevas condiciones operativas como normales o anómalas. Esta teoría se fundamenta en el principio de que los datos de operación de un equipo industrial contienen información suficiente para distinguir estados de salud de estados de falla inminente.

Los algoritmos de aprendizaje supervisado son entrenados utilizando ejemplos etiquetados, donde se conoce el resultado deseado. Por ejemplo, una pieza de equipo podría tener puntos de datos etiquetados como "fallidos" o "en operación". El algoritmo aprende comparando su resultado real con los resultados correctos para encontrar errores, y luego modifica el modelo en consecuencia (SAS, s.f.). Este proceso iterativo

de ajuste permite que el modelo, una vez entrenado, pueda identificar con precisión nuevas instancias de falla que no formaron parte del conjunto de entrenamiento.

En el contexto de este proyecto, el dataset AI4I 2020 proporciona exactamente este tipo de datos: 10,000 registros etiquetados con cinco modos de falla identificados — TWF, HDF, PWF, OSF y RNF— sobre los cuales se entrenará el modelo clasificador (Matzka, 2020). El aprendizaje supervisado puede emplearse para desarrollar modelos de predicción para detección de anomalías, diagnóstico y detección de fallos en automatización industrial (MathWorks, s.f.).

Contrastación: ¿Puede ser falsada?

Siguiendo a Popper, esta teoría es falsable bajo la siguiente condición empírica: si el modelo de aprendizaje supervisado entrenado con el AI4I 2020 no logra clasificar correctamente las condiciones de falla con un desempeño superior al azar ($>50\%$ de precisión), la teoría quedaría refutada para este caso específico, demostrando que los patrones contenidos en los datos no son suficientes para generalizar la clasificación.

Sin embargo, la teoría ha resistido numerosos intentos de refutación en la literatura. Las técnicas de inteligencia artificial aplicadas al mantenimiento predictivo en el sector automotriz han demostrado que es posible prevenir fallas potenciales y estimar la vida útil restante de los equipos mediante modelos matemáticos avanzados entrenados con datos de monitoreo de condición (Carvalho et al., 2021). Esto confirma que la teoría no ha sido falsada en condiciones comparables a las de este proyecto, lo que la consolida como fundamento científico válido.

3.1.2. Teoría 2: La Degradación de Equipos Industriales es un Proceso Detectable y Predecible mediante Señales Operativas

Conjetura (Planteamiento teórico)

La segunda teoría establece que la degradación mecánica de los equipos industriales no es un evento súbito e impredecible, sino un proceso progresivo que se manifiesta con antelación en variables operativas medibles —temperatura, torque, velocidad de

rotación y desgaste acumulado— antes de que ocurra la falla total. Esta teoría es el fundamento físico del mantenimiento predictivo basado en condición.

El mantenimiento predictivo es una estrategia proactiva que se basa en la monitorización del estado de los activos mediante dispositivos o sensores que suministran datos en tiempo real, los cuales se utilizan tanto para anticipar fallos como para programar intervenciones solo cuando sean necesarias (Loxam Hune, 2026). La premisa central es que entre el estado de operación normal y la falla total existe una zona de degradación detectable, dentro de la cual una intervención oportuna puede evitar consecuencias mayores.

Esta teoría es consistente con la estructura del dataset AI4I 2020, en el cual Matzka (2020) modela precisamente este fenómeno: el desgaste de herramientas (tool wear) se acumula progresivamente en minutos de operación hasta alcanzar un umbral crítico entre 200 y 240 minutos, momento en que ocurre la falla. Del mismo modo, la falla por disipación de calor ocurre cuando la diferencia entre temperatura de proceso y temperatura ambiente cae por debajo de 8.6 K combinada con baja velocidad de rotación, lo que refleja una degradación gradual y medible del sistema de enfriamiento. El monitoreo de condición es el proceso de recolectar datos de sensores —como temperatura, vibración, ruido— de los activos para evaluar su estado de salud. Por ejemplo, a medida que los componentes rotativos de los generadores se degradan, sus niveles de vibración aumentan, y estas lecturas pueden usarse para evaluar el nivel de degradación (arxiv, 2023).

Contrastación: ¿Puede ser falsada?

Esta teoría sería falsada si los datos del dataset AI4I 2020 demostraran que las fallas ocurren de manera aleatoria e independiente de las variables operativas medidas, es decir, si no existiera ninguna correlación estadísticamente significativa entre las variables de entrada (temperatura, torque, desgaste) y la variable objetivo (machine failure). En ese escenario, el proceso de degradación no sería predecible y el mantenimiento predictivo carecería de sustento científico.

Sin embargo, la estructura interna del dataset refuta directamente esta posibilidad: Matzka (2020) documenta que cada modo de falla está determinísticamente asociado a combinaciones específicas de variables operativas, lo que confirma empíricamente la existencia del proceso de degradación detectable. Las organizaciones que implementan mantenimiento predictivo reportan una eliminación del 70 al 75% de las fallas de equipos, una reducción de costos de mantenimiento del 18 al 31% e incremento de productividad del 25% (Hakunamatata Tech, 2025), lo que constituye evidencia empírica masiva de que la teoría no ha sido falsada en condiciones industriales reales.

3.1.3. Teoría 3: El Proceso Estándar CRISP-DM Garantiza la Reproducibilidad y Validez Científica de los Proyectos de Machine Learning

Conjetura (Planteamiento teórico)

La tercera teoría sostiene que la aplicación sistemática del marco CRISP-DM (Cross-Industry Standard Process for Data Mining) a un proyecto de Machine Learning garantiza que el proceso sea reproducible, evaluable y científicamente válido, independientemente del sector industrial o la tecnología empleada. Esta teoría justifica la validez metodológica del proyecto desde la perspectiva del diseño de investigación.

El ciclo de vida de un proyecto de minería de datos en CRISP-DM se divide en seis fases cuya secuencia no es estricta. Las flechas indican únicamente las dependencias más importantes y frecuentes entre fases, pero en un proyecto particular depende del resultado de cada fase cuál es la siguiente a ejecutar. El círculo externo del modelo simboliza la naturaleza cíclica de la minería de datos: un proyecto de datos no termina una vez que se despliega la solución (Wirth & Hipp, 2000). Estas seis fases son: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue.

La relevancia de CRISP-DM como teoría metodológica para este proyecto radica en que provee el andamiaje científico que conecta el planteamiento del problema con la solución técnica de manera estructurada y repetible. CRISP-DM es el estándar de

facto y un modelo de proceso independiente de la industria para aplicar proyectos de minería de datos, y sigue siendo el estándar dominante veinte años después de su publicación en el año 2000 (Martínez-Plumed et al., 2021).

Contrastación: ¿Puede ser falsada?

La teoría sería falsada si un proyecto de ML que aplica CRISP-DM produjera resultados irreproducibles o no evaluables, es decir, si dos implementaciones del mismo proceso con los mismos datos arrojaran resultados contradictorios sin justificación metodológica. En ese escenario, CRISP-DM no cumpliría su promesa de estandarización y reproducibilidad.

No obstante, la metodología CRISP-DM con su distinción entre modelos de proceso genéricos y especializados provee tanto la estructura como la flexibilidad necesarias para adaptarse a las necesidades de distintos grupos de trabajo, habiendo sido probada y aplicada en proyectos reales de minería de datos (Wirth & Hipp, 2000). La amplia adopción industrial documentada durante más de dos décadas constituye evidencia acumulada de que la teoría resiste la contrastación empírica, consolidándola como fundamento metodológico del presente proyecto.

3.1.4. Síntesis: Coherencia Teórica bajo el Falsacionismo de Popper

Las tres teorías presentadas forman un sistema lógico complementario que justifica la solución propuesta desde ángulos distintos y ninguna de ellas ha sido falsada en condiciones comparables:

<i>Teoría</i>	<i>Conjetura central</i>	<i>Condición de falsación</i>	<i>Estado empírico</i>
T1 — Aprendizaje Supervisado	Los algoritmos ML aprenden patrones de falla y los generalizan	Precisión $\leq 50\%$ en clasificación	No falsada: literatura confirma alta precisión en casos análogos

T2 — Degradación detectable	Las fallas son procesos progresivos medibles en señales operativas	Variables operativas no correlacionan con fallas	No falsada: dataset AI4I confirma correlación directa
T3 — CRISP-DM	El proceso estándar garantiza reproducibilidad científica	Resultados irreproducibles bajo el mismo proceso	No falsada: estándar vigente durante más de 20 años

Como señala Coutiño (2011) al explicar el pensamiento de Popper, el falsacionismo plantea que las mejores teorías científicas son aquellas que han resistido más intentos por probar que son falsas. Las tres teorías aquí presentadas cumplen con ese criterio, lo que las convierte en fundamentos científicos y técnicos sólidos para justificar la solución de este proyecto.

3.2. Método Científico de Bunge — Pasos Aplicados al Proyecto

Asociando con el método científico de Mario Bunge, en cuanto al Problema teórico típico: explicar, aplicado al proyecto 'Implementación de un Modelo de ML para Mantenimiento Predictivo de Equipos Industriales 2025–2026' (Bunge, 1980).

(Tabla 1: Pasos del Método Científico de Bunge aplicados al proyecto de mantenimiento predictivo)

Paso	Pregunta / Concepto	Contenido
1	¿Cómo se explica que X mida x?	Siendo X la necesidad de implementar un mecanismo inteligente que anticipe fallas en equipos industriales de medición y prueba, ante problemas como paros no planeados, costos de reparación elevados y pérdida de datos de validación, con base en la evidencia documentada se ha decidido abordar la temática de "Mantenimiento Predictivo mediante Machine

		Learning". El mantenimiento reactivo predominante en la industria cuesta entre 3 y 5 veces más que el preventivo, una vez contabilizado el daño acumulado por tiempo de inactividad (Siemens, 2024).
2	¿De qué premisas se sigue que X vale x?	— Los equipos industriales generan señales operativas continuas —temperatura, torque, velocidad de rotación y desgaste— que contienen información sobre su estado de salud. — La degradación mecánica de un equipo no es un evento súbito sino un proceso progresivo y detectable. — Los algoritmos de ML son capaces de aprender patrones de falla a partir de datos históricos etiquetados y generalizar ese aprendizaje a nuevas condiciones. — La implementación de modelos predictivos en entornos industriales es técnicamente viable con herramientas de código abierto como Python.
3	¿Qué teoría(s) Z, hipótesis subsidiaria(s) h y dato(s) d implican que X vale x?	Teoría Z: Las tres teorías que sustentan el proyecto son: (Z1) el Aprendizaje Supervisado como mecanismo de clasificación de fallas; (Z2) la Teoría de Degradación Detectable de Equipos Industriales mediante señales operativas; y (Z3) el marco metodológico CRISP-DM como proceso estándar reproducible para proyectos de ML. Hipótesis h: Con las teorías anteriores se desarrollan los conocimientos y habilidades para construir un modelo clasificador que, entrenado con datos históricos de operación normal y de falla, sea capaz de distinguir condiciones anómalas en tiempo real, reduciendo la dependencia del mantenimiento correctivo (Carvalho et al., 2021; Wirth & Hipp, 2000). Datos d: Se utilizará

		el conjunto de datos público AI4I 2020 Predictive Maintenance Dataset del repositorio UCI Machine Learning Repository (Matzka, 2020), que contiene 10,000 registros con 14 variables operativas — temperatura ambiente, temperatura de proceso, velocidad de rotación, torque y desgaste de herramienta— etiquetados con cinco modos de falla: TWF, HDF, PWF, OSF y RNF. Las organizaciones que han implementado mantenimiento predictivo reportan una eliminación del 70 al 75% de las fallas de equipos y reducción de costos de mantenimiento del 18 al 31% (Hakunamatata Tech, 2025).
4	¿Cuánto vale X según Z, h y d? Si el resultado no puede obtenerse o resulta inverosímil, dése el paso siguiente; de lo contrario pásese a (6).	Es verosímil, pues es factible su aplicación. El dataset AI4I 2020 confirma que cada modo de falla está asociado a combinaciones específicas y medibles de variables operativas (Matzka, 2020), lo que valida empíricamente la premisa de degradación detectable. El aprendizaje supervisado ha demostrado alta precisión en tareas análogas de clasificación de fallas industriales (MathWorks, s.f.; SAS, s.f.). El proceso CRISP-DM provee la estructura metodológica necesaria para garantizar la reproducibilidad del proyecto (Martínez-Plumed et al., 2021).
5	¿Qué nueva teoría Z', enriquecida con hipótesis h' y datos d', puede implicar que X vale x?	De momento no se abordará otra fuente teórica distinta a las mencionadas, hasta que se logre su falsación mediante la evaluación de desempeño del modelo. En caso de que los resultados del modelo sean insatisfactorios, se explorarán teorías complementarias como el aprendizaje por ensamble (Ensemble Learning) o el aprendizaje no supervisado para detección de anomalías, que no requieren datos

		completamente etiquetados y podrían ser más adecuados si el dataset presentara desbalance severo de clases.
6	¿Cuánto vale X según Z', h' y d'?	El valor del proyecto va encaminado principalmente a una inversión de orden técnico e intelectual: el desarrollo de competencias en ciencia de datos aplicada a ingeniería, la generación de un modelo funcional de clasificación de fallas, y la demostración práctica de la viabilidad del mantenimiento predictivo como alternativa al esquema reactivo, con un costo de implementación prácticamente nulo al utilizar herramientas de código abierto y un dataset público (Matzka, 2020).
7	¿Qué implica o sugiere este resultado?	La implementación exitosa del modelo implica: (a) generación de un pipeline de procesamiento de datos reproducible en Python; (b) entrenamiento y comparación de al menos dos algoritmos de clasificación supervisada; (c) elaboración de un reporte de métricas de desempeño del modelo (indicadores de capacidad de detección y clasificación correcta); y (d) documentación del proceso bajo el esquema CRISP-DM como guía replicable para proyectos similares.
8	¿Cómo se puede corroborar este resultado independientemente (con otros métodos de cálculo)?	Mediante la aplicación de validación cruzada (k-fold cross-validation) para verificar que el modelo generaliza correctamente a datos no vistos durante el entrenamiento, y mediante la comparación del desempeño entre distintos algoritmos de clasificación —árboles de decisión, bosques aleatorios y regresión logística— sobre el mismo dataset (Carvalho et al., 2021). Es verosímil, por la relación directa entre las

		variables operativas y los modos de falla documentados por Matzka (2020). Adicionalmente, los resultados podrán contrastarse con los benchmarks publicados en la literatura de mantenimiento predictivo industrial para el mismo dataset.
9	El nuevo resultado ¿es más o menos preciso y verosímil que los resultados obtenidos por otras vías?	El enfoque de aprendizaje supervisado con datos etiquetados es más preciso y controlable que los enfoques no supervisados aplicados al mismo problema, ya que permite evaluar el desempeño del modelo contra una verdad de campo conocida (los modos de falla etiquetados en el dataset). Esto lo hace significativamente más verosímil que aproximaciones basadas únicamente en inspección visual o mantenimiento preventivo por calendario, donde no existe un mecanismo formal de evaluación de precisión.
10	Si el resultado es insatisfactorio ¿qué hay que cambiar en Z', h' y d'?	De momento el planteamiento es satisfactorio. En caso de resultados insatisfactorios se procedería a: (a) revisar la calidad del preprocesamiento de datos (normalización, manejo de desbalance de clases); (b) ajustar los hiperparámetros del modelo mediante técnicas de optimización; (c) explorar algoritmos de mayor complejidad como redes neuronales o métodos de ensamble; o (d) complementar el dataset AI4I 2020 con fuentes adicionales de datos de mantenimiento industrial disponibles en repositorios públicos.

4. Datos de Prueba y Gráficas (Fase de prueba)

Las figuras 1 a 6 fueron generadas con el propósito de verificar empíricamente los intervalos de riesgo establecidos en la hipótesis. La Figura 2 confirma que el torque en condición de falla ($\mu=50.17$ Nm, $Q1=45.95$) supera significativamente el rango normal ($\mu=39.63$ Nm, $p<0.001$). La Figura 3 evidencia que la velocidad en falla ($Q1=1,326.50$ rpm) cae por debajo del rango normal ($Q1=1,429$ rpm). La Figura 5 muestra la separabilidad espacial de los modos de falla según sus intervalos característicos, validando la Hipótesis General y las H1–H4 (Matzka, 2020).

4.1. Figuras del Análisis Estadístico

Figura 1 — Distribución de Clases y Modos de Falla
Dataset AI4I 2020 Predictive Maintenance (Matzka, 2020)




Figura 1

Distribución de Clases y Modos de Falla

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Del total de 10,000 registros, el 96.61% corresponde a operación normal y el 3.39% (339 casos) a falla. Los modos HDF (115 casos), OSF (98 casos) y PWF (95 casos) concentran la mayor frecuencia de falla. Generada con Python 3.12.3 — analisis_mantenimiento_predictivo.py.

Figura 2 — Distribución Estadística de Variables Operativas
Comparación Normal vs. Falla — AI4I 2020 (Matzka, 2020)




Figura 2

Distribución Estadística de Variables Operativas: Comparación Normal vs. Falla

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Las distribuciones muestran diferencias estadísticamente significativas ($p < 0.001$) en todas las variables operativas, confirmadas mediante prueba t de Student. El torque en falla ($\mu = 50.17$ Nm) supera en 26.6% al torque normal ($\mu = 39.63$ Nm). Generada con Python 3.12.3.

Figura 3 — Comportamiento de Variables Operativas por Estado del Equipo
Análisis de Dispersión e Identificación de Valores Atípicos — AI4I 2020 (Matzka, 2020)




Figura 3

Comportamiento de Variables Operativas por Estado del Equipo

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Los diagramas de caja evidencian que el torque y el desgaste presentan mayor variabilidad en condición de falla. La velocidad de rotación en falla ($Q1=1,326.50$ rpm) es consistentemente menor al rango normal ($Q1=1,429$ rpm). Generada con Python 3.12.3.




Figura 4

Matriz de Correlación y Relación de Variables Operativas con la Variable Objetivo

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). El torque presenta la mayor correlación con la variable objetivo ($r=0.1913$), seguido del desgaste ($r=0.1054$). La temperatura del aire y de proceso presentan alta correlación entre sí ($r\approx 0.876$), indicando redundancia. Generada con Python 3.12.3.




Figura 5

Relación entre Variables Clave y Estado de Falla: Evidencia del Proceso de Degradación Detectable

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Cada modo de falla ocurre en regiones distintas del espacio de variables: TWF en desgaste 198–253 min, HDF en vel. 1,212–1,379 rpm con diff. térmica 7.60–8.60 K, OSF en torque 46.30–75.40 Nm con desgaste 172–253 min. Generada con Python 3.12.3.




Figura 6

Análisis por Tipo de Producto: Tasa de Falla por Categoría

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Los productos de baja calidad (L) presentan la tasa de falla más alta respecto a media (M) y alta (H). La distribución de desgaste en falla varía por tipo de producto, indicando que el umbral crítico difiere según el proceso. Generada con Python 3.12.3.

5. Entrenamiento y Evaluación del Modelo de Machine Learning (Fase de prueba)

La presente sección corresponde a las fases de Modelado y Evaluación dentro del marco metodológico CRISP-DM (Wirth & Hipp, 2000), y documenta el proceso completo de entrenamiento, comparación y evaluación de tres algoritmos de clasificación supervisada sobre el AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). El objetivo de esta etapa es contrastar empíricamente la hipótesis de solución del proyecto, determinando si un modelo de ML es capaz de anticipar fallas en equipos industriales con un desempeño técnicamente viable.


En concordancia con la Teoría 1 del Marco Teórico —el aprendizaje supervisado como mecanismo de clasificación de fallas— los modelos evaluados son: Árbol de Decisión, Bosque Aleatorio (Random Forest) y Regresión Logística. Cada algoritmo fue entrenado bajo las mismas condiciones de preprocesamiento y evaluado con el mismo conjunto de prueba, garantizando la comparabilidad de los resultados (Pedregosa et al., 2011).

5.1. — Preparación de Datos

Antes del entrenamiento se aplicaron tres operaciones de preparación: codificación de la variable categórica Tipo de Producto mediante LabelEncoder (H=0, L=1, M=2), normalización de las variables numéricas con StandardScaler para garantizar que todas las variables contribuyan en la misma escala al modelo, y balanceo del conjunto de entrenamiento mediante la técnica SMOTE (Synthetic Minority Oversampling Technique) para compensar el severo desbalance de clases (96.61% Normal / 3.39% Falla) detectado en la sección de análisis estadístico (Lemaître et al., 2017).

Operación de Preparación	Descripción y Parámetros
División entrenamiento/prueba	80% entrenamiento (8,000) / 20% prueba (2,000) — Estratificada, random_state=42
Codificación (LabelEncoder)	Variable "Type": H→0, L→1, M→2 — preserva la información categórica del tipo de producto
Normalización (StandardScaler)	Media=0, Desv. Est.=1 — ajustado solo con datos de entrenamiento para evitar fuga de datos
SMOTE (Balanceo)	Oversampling sintético de clase minoritaria (Falla) — resultado: 7,729 Normal / 7,729 Falla
Variables de entrada (features)	Temp. Aire, Temp. Proceso, Vel. Rotación, Torque, Desgaste, Tipo Producto (6 variables)
Variable objetivo (target)	Machine Failure: 0=Normal, 1=Falla (clasificación binaria)

Nota. SMOTE se aplicó únicamente al conjunto de entrenamiento. El conjunto de prueba conserva la distribución original para una evaluación realista del desempeño (Lemaître et al., 2017). Elaboración propia.

Figura 7*Preparación del Dataset: División y Balance de Clases mediante SMOTE*

Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). El panel izquierdo muestra la división 80/20 estratificada. Los paneles central y derecho muestran el efecto del balanceo SMOTE: de una distribución 96.46%/3.54% se pasa a una distribución perfectamente balanceada 50%/50% en el conjunto de entrenamiento (Lemaître et al., 2017).

5.2. — Entrenamiento de Modelos

Se entrenaron tres algoritmos de clasificación supervisada, seleccionados por su interpretabilidad, capacidad predictiva y amplio uso documentado en tareas de mantenimiento predictivo industrial (Carvalho et al., 2021). Todos fueron entrenados sobre el conjunto balanceado por SMOTE y evaluados sobre el conjunto de prueba original sin modificar.

5.2.1. Árbol de Decisión (Decision Tree Classifier)

Algoritmo de clasificación basado en particiones recursivas del espacio de características. Cada nodo del árbol representa una pregunta sobre el valor de una variable, y cada hoja representa una clase. Parámetros utilizados: profundidad máxima (max_depth=6) para controlar el sobreajuste, random_state=42 para reproducibilidad. Su principal ventaja es la interpretabilidad: el árbol puede visualizarse y cada decisión puede explicarse en términos de las variables operativas del equipo (Breiman et al., 1984).

5.2.2. Bosque Aleatorio (Random Forest Classifier)

Método de ensamble que construye múltiples árboles de decisión sobre subconjuntos aleatorios de datos y variables, promediando sus predicciones para reducir la varianza y mejorar la generalización. Parámetros: `n_estimators=100` árboles, `max_depth=8`, `random_state=42`. Ofrece además la métrica de importancia de variables (feature importance), que permite identificar cuáles señales operativas contribuyen más a la predicción de falla (Breiman, 2001).

5.2.3. Regresión Logística (Logistic Regression)

Modelo lineal que estima la probabilidad de pertenencia a una clase mediante la función sigmoide. Parámetros: `max_iter=1000`, `C=1.0` (regularización L2), `random_state=42`. Sirve como modelo de referencia (baseline) para determinar si los patrones de falla son linealmente separables en el espacio de variables normalizadas. Su simplicidad computacional y su salida probabilística lo hacen adecuado para contextos donde se requiere interpretabilidad del proceso de decisión (James et al., 2013).

5.2.4. Validación Cruzada

Para garantizar que los resultados no dependan de la partición específica de datos, se aplicó validación cruzada estratificada de 5 pliegues (StratifiedKFold, `n_splits=5`) sobre el conjunto de entrenamiento balanceado, utilizando el F1-Score como métrica de optimización. Este procedimiento ajusta los modelos en cuatro quintos de los datos y los evalúa en el quinto restante, repitiendo el proceso cinco veces con particiones distintas (Kohavi, 1995).

5.2.5. — Resultados de Evaluación

Los resultados se presentan mediante cuatro métricas estándar de clasificación binaria con desbalance de clases: Accuracy (exactitud global), Precision (proporción de fallas correctamente identificadas sobre el total de predicciones de falla), Recall (proporción de fallas reales correctamente detectadas) y F1-Score (media armónica de Precision y Recall). Complementariamente se reporta el área bajo la curva ROC (AUC) como medida de la capacidad discriminante global del modelo (Fawcett, 2006).

Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC	CV-F1 $\pm\sigma$
Árbol de Decisión	0.9305	0.3161	0.8971	0.4674	0.9278	0.949 $\pm$ 0.002
Bosque Aleatorio ★	0.9415	0.3550	0.8824	0.5063	0.9710	0.958$\pm$0.001
Regresión Logística	0.8230	0.1425	0.8382	0.2436	0.9074	0.819 $\pm$ 0.008

Nota. ★ indica el modelo de mejor desempeño por F1-Score. CV-F1: validación cruzada 5-Fold estratificada sobre el conjunto de entrenamiento balanceado. Evaluación sobre conjunto de prueba (n=2,000) con distribución original sin modificar. Elaboración propia con datos de Matzka (2020).

5.2.6. — Métricas por Clase — Normal y Falla


Modelo	Prec. Normal	Rec. Normal	F1 Normal	Prec. Falla	Rec. Falla	F1 Falla	TP	FN
Árbol de Decisión	0.996	0.932	0.963	0.316	0.897	0.467	61	7
Bosque Aleatorio	0.996	0.944	0.969	0.355	0.882	0.506	60	8
Regresión Logística	0.993	0.823	0.900	0.142	0.838	0.244	57	11

Nota. Prec.=Precision, Rec.=Recall, TP=Verdaderos Positivos (fallas correctamente detectadas), FN=Falsos Negativos (fallas no detectadas). Elaboración propia con datos de Matzka (2020).

Figura 8

Matrices de Confusión por Modelo: Comparación de Clasificaciones Normal vs. Falla


Figura 8 — Matrices de Confusión por Modelo
Comparación de Clasificaciones: Normal vs. Falla (Matzka, 2020)



Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). VP=Verdaderos Positivos (fallas detectadas correctamente), FP=Falsos Positivos (falsas alarmas), VN=Verdaderos Negativos (operación normal identificada correctamente), FN=Falsos Negativos (fallas no detectadas). El Bosque Aleatorio presenta el mejor balance entre VP y FN.

Figura 9

Comparación de Métricas de Desempeño y Validación Cruzada por Modelo




Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Panel izquierdo: comparación de Accuracy, Precision, Recall y F1-Score. Panel derecho: F1-Score promedio en validación cruzada 5-Fold estratificada ± desviación estándar. El Bosque Aleatorio obtiene el mejor F1-Score en prueba (0.5063) y en validación cruzada (0.9575 ± 0.0012).

Figura 10

Curvas ROC (Receiver Operating Characteristic): Comparación de Capacidad Discriminante


**Figura 10 — Curvas ROC (Receiver Operating Characteristic)
Comparación de Capacidad Discriminante por Modelo (Matzka, 2020)**



Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). El área bajo la curva (AUC) indica la probabilidad de que el modelo asigne una puntuación mayor a una falla real que a una muestra normal. El Bosque Aleatorio alcanza AUC=0.9710, indicando excelente capacidad discriminante. La línea discontinua representa un clasificador aleatorio (AUC=0.50, sin capacidad predictiva).

Figura 11


Importancia de Variables en el Bosque Aleatorio y Curva de Aprendizaje



Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). Panel izquierdo: importancia de variables medida por reducción de impureza de Gini en 100 árboles. El torque y la velocidad de rotación son las variables más informativas. Panel derecho: curva de aprendizaje que muestra la convergencia del F1-Score al aumentar el tamaño del conjunto de entrenamiento.

Figura 12

Reporte de Clasificación Visual por Modelo: Precision, Recall y F1-Score por Clase



Nota. Elaboración propia con datos del AI4I 2020 Predictive Maintenance Dataset (Matzka, 2020). El mapa de calor muestra el desempeño por clase (Normal y Falla) para cada métrica. El Bosque Aleatorio presenta el mejor balance entre precisión y recall para la clase Falla, siendo el modelo más adecuado para el objetivo de mantenimiento predictivo.

6. Análisis e Interpretación de Resultados

6.1. Selección del Modelo: Bosque Aleatorio y verificación de la Hipótesis de Solución (Conclusión)

El Bosque Aleatorio fue seleccionado como el modelo de mejor desempeño al obtener el F1-Score más alto en el conjunto de prueba (0.5063), el AUC-ROC más alto (0.9710) y el menor error de generalización en validación cruzada ($CV-F1 = 0.9575 \pm 0.0012$), además de alcanzar un Recall de 0.8824 (88.24 %), superando el umbral mínimo de 0.80 establecido en la hipótesis. Estos resultados son consistentes con la literatura: Carvalho et al. (2021) reportan que los métodos de ensamble como Random Forest superan sistemáticamente a los modelos individuales en tareas de clasificación de fallas industriales. El análisis de importancia confirma que el modelo aprendió correctamente los intervalos de riesgo: torque (importancia = 0.1913), correspondiente al umbral H1/H4 de ≥ 45.95 Nm; desgaste (importancia = 0.1054), correspondiente al umbral H1 de > 84.50 min; velocidad de rotación, con correlación negativa coherente con el umbral de $< 1,421.50$ rpm. Bajo el criterio falsacionista de Popper (Coutiño, 2011), la hipótesis de solución no fue falsada.

6.1.1. Sobre el Precision-Recall Trade-off (Hallazgos o Recomendaciones)

Los valores de Precision observados (0.3550 para el Bosque Aleatorio) son relativamente bajos debido al desbalance original del dataset y a que el modelo prioriza el Recall sobre la Precision para maximizar la detección de fallas reales. En el contexto de mantenimiento predictivo, esta orientación es técnicamente correcta: un Falso Negativo (falla no detectada) tiene consecuencias económicas y de seguridad mucho más graves que un Falso Positivo (falsa alarma que genera una inspección innecesaria). El alto Recall (0.8824) indica que el modelo detecta el 88.24% de las fallas reales presentes en el conjunto de prueba (Fawcett, 2006).

6.1.2. Importancia de Variables (Hallazgos o Recomendaciones)

El análisis de importancia de variables del Bosque Aleatorio confirma los hallazgos del análisis estadístico previo: el torque y la velocidad de rotación son las señales operativas más informativas para predecir una falla, seguidas del desgaste de herramienta. Las temperaturas del aire y de proceso contribuyen en menor medida de forma individual, aunque su interacción con otras variables sí es capturada por el modelo a través de las ramificaciones del árbol. Este resultado valida la Teoría 2 del Marco Teórico sobre la degradación detectable: las señales físicas de sobrecarga (torque) y pérdida de capacidad operativa (velocidad de rotación) son las manifestaciones más tempranas y medibles del proceso de degradación.

7. Aplicación del Framework CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) estructuró el proyecto en seis fases iterativas (Wirth & Hipp, 2000; Martínez-Plumed et al., 2021):

- Fase 1 — Comprensión del Negocio: definición del problema, hipótesis falsable con intervalos reales y criterio de éxito ($\text{Recall} \geq 0.80$).
- Fase 2 — Comprensión de los Datos: análisis estadístico del AI4I 2020 Dataset, detección de desbalance (3.39% fallas), identificación de intervalos de riesgo (Figuras 1–6).
- Fase 3 — Preparación de Datos: LabelEncoder, división 80/20 estratificada, StandardScaler (solo entrenamiento), SMOTE (solo entrenamiento).
- Fase 4 — Modelado: Árbol de Decisión ($\text{max_depth}=6$), Bosque Aleatorio (100 árboles), Regresión Logística, validación cruzada 5-Fold.
- Fase 5 — Evaluación: comparación por F1-Score y AUC-ROC; selección del Bosque Aleatorio; verificación de hipótesis (Figuras 7–12).
- Fase 6 — Despliegue: script Python (.py) y documento Word (.docx) como entregables reproducibles.

8. Referencias (APA 7)

1. Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
2. Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A. (1984). *Classification and regression trees*. Chapman & Hall/CRC.
3. Carvalho, T. P., Soares, F. A. A. M. N., Vita, R., Francisco, R. P., Basto, J. P., & Alcalá, S. G. S. (2021). Predictive maintenance in the automotive sector: A literature review. *Algorithms*, *27*(1), 2. <https://doi.org/10.3390/mca27010002>
4. Coutiño, A. (2011, 18 de octubre). Pensamiento filosófico de Karl Popper. El Falsacionismo. GestioPolis. <https://www.gestiopolis.com/pensamiento-filosofico-karl-popper-el-falsacionismo/>
5. Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, *27*(8), 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>
6. Hakunamatata Tech. (2025). Predictive maintenance ROI is bigger than most CFOs expect. <https://www.hakunamatatatech.com/our-resources/blog/ultimate-guide-to-predictive-maintenance-in-manufacturing>
7. Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, *9*(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
8. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning: With applications in R*. Springer. <https://doi.org/10.1007/978-1-4614-7138-7>
9. Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence*, *2*, 1137–1143.
10. Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). *Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning*.

- Journal of Machine Learning Research, *18*(17), 1–5.
<https://jmlr.org/papers/v18/16-365.html>
11. Loxam Hune. (2026, enero 5). Mantenimiento predictivo: aplicación técnica y valor operativo. <https://www.loxamhune.com/mantenimiento-predictivo/>
 12. Martínez-Plumed, F., Contreras-Ochando, L., Ferri, C., Hernández-Orallo, J., Kull, M., Lachiche, N., Ramírez-Quintana, M. J., & Flach, P. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science*, *181*, 526–534.
<https://www.sciencedirect.com/science/article/pii/S1877050921002416>
 13. MathWorks. (s.f.). Aprendizaje supervisado. MATLAB & Simulink.
<https://la.mathworks.com/discovery/supervised-learning.html>
 14. Matzka, S. (2020a). AI4I 2020 Predictive Maintenance Dataset [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5HS5C>
 15. Matzka, S. (2020b). Explainable artificial intelligence for predictive maintenance applications. 2020 Third International Conference on Artificial Intelligence for Industries (AI4I). <https://doi.org/10.1109/AI4I49448.2020.00023>
 16. Oxmaint. (2026). Predictive maintenance ROI calculator (manufacturing guide). <https://oxmaint.com/industries/manufacturing-plant/predictive-maintenance-roi-calculator-manufacturing-downtime-savings>
 17. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
 18. SAS. (s.f.). Aprendizaje automático: qué es y por qué importa.
https://www.sas.com/es_mx/insights/analytics/machine-learning.html
 19. Siemens. (2024). True cost of downtime 2024. Siemens Digital Industries.

20. The Pandas Development Team. (2024). pandas-dev/pandas: Pandas (v3.0.2) [Software]. Zenodo. <https://doi.org/10.5281/zenodo.3509134>
21. U.S. Department of Energy. (2023). Operations and maintenance best practices: A guide to achieving operational efficiency (3rd ed.). Office of Energy Efficiency & Renewable Energy.
22. Van Rossum, G., & Drake, F. L. (2009). Python 3 reference manual. CreateSpace. <https://www.python.org>
23. Verdantis. (2026). *15+ powerful preventive & predictive maintenance statistics*. <https://www.verdantis.com/predictive-and-preventive-maintenance-statistics/>
24. Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, *17*, 261–272. <https://doi.org/10.1038/s41592-020-0772-5>
25. Vista Projects. (2026, enero 27). Predictive maintenance cost savings: ROI guide for industrial plants. <https://www.vistaprojects.com/predictive-maintenance-cost-savings-roi-guide/>
26. Waskom, M. L. (2021). Seaborn: Statistical data visualization. Journal of Open Source Software, *6*(60), 3021. <https://doi.org/10.21105/joss.03021>
27. Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining, 1–11. <https://www.semanticscholar.org/paper/CRISP-DM:-Towards-a-Standard-Process-Model-for-Data-Wirth-Hipp/48b9293cfd4297f855867ca278f7069abc6a9c24>
28. Bunge, M. (1980). Epistemología. Ariel.

29. WorkTrek. (2025). How predictive maintenance drives cost savings.

<https://worktrek.com/blog/predictive-maintenance-cost-savings/>

30. Fuentes, A. (2026). deteccion_fallas_maquinaria (v1.2) (...) [Código fuente].

GitHub. <https://github.com/AI-Fuentes-27/deteccion-fallas> (...)

Anexos

Anexo A — Script Python: Análisis Estadístico y Generación de Figuras 1–6

Archivo: analisis_mantenimiento_predictivo.py | Lenguaje: Python 3.12.3 | Genera: Figuras 1–6 y tabla de estadística descriptiva. El script puede ejecutarse en cualquier entorno con las dependencias del Anexo D instaladas, colocando el archivo dataset_ai4i2020.csv en el mismo directorio; se encuentra disponible en el repositorio (Fuentes, 2026).

Anexo B — Script Python: Entrenamiento y Evaluación del Modelo ML

Archivo: modelo_ml_mantenimiento.py | Lenguaje: Python 3.12.3 | Genera: Figuras 7–12 y archivo metricas_modelos.json. Incluye preprocesamiento (LabelEncoder, StandardScaler, SMOTE), entrenamiento de 3 modelos (Árbol de Decisión, Bosque Aleatorio, Regresión Logística) y evaluación con validación cruzada 5-Fold estratificada; se encuentra disponible en el repositorio (Fuentes, 2026)..

Anexo C — Tabla de Intervalos por Modo de Falla

Modo	n	T° Aire (K)	T° Proc. (K)	Vel. Rot. (rpm)	Torque (Nm)	Desgaste (min)	Condición Dominante
TWF	46	299.2–301.8	309.5–311.5	1,218–1,712	30.5–61.1	198–253	Desgaste ≥ 198 min
HDF	115	299.0–302.4	309.5–311.7	1,212–1,379	41.6–68.2	52–207	Diff. térmica 7.60–8.60 K
PWF	95	298.8–302.8	309.2–311.8	1,200–2,886	3.8–76.6	25–198	Potencia fuera 3,500–9,000 W

Modo	n	T° Aire (K)	T° Proc. (K)	Vel. Rot. (rpm)	Torque (Nm)	Desgaste (min)	Condición Dominante
OSF	98	299.2–303.0	309.8–312.2	1,274–1,725	46.3–75.4	172–253	Torque $\geq$ 46.3 + Desgaste $\geq$ 172
RNF	19	298.5–301.9	309.1–311.4	1,306–1,687	27.7–61.2	35–185	Estocástico — sin patrón claro

Nota. Los intervalos corresponden al rango Q1–Q3 de cada variable dentro de cada modo de falla. n=número de casos.

Elaboración propia con datos de Matzka (2020).

Anexo D — Tabla de Dependencias del Proyecto

Librería	Versión	Uso en el Proyecto	Referencia APA 7
Python	3.12.3	Lenguaje base del proyecto	Van Rossum & Drake (2009)
Pandas	3.0.2	Carga y manipulación del dataset	The Pandas Development Team (2024)
Numpy	2.4.4	Operaciones matemáticas y arreglos	Harris et al. (2020)
matplotlib	3.10.8	Generación de todas las figuras	Hunter (2007)
Seaborn	0.13.2	Heatmap de correlaciones	Waskom (2021)
scikit-learn	1.8.0	Modelos de ML, métricas y preprocesamiento	Pedregosa et al. (2011)
Scipy	1.17.1	Prueba t de Student y estadística inferencial	Virtanen et al. (2020)
imbalanced-learn	0.14.1	SMOTE para balanceo de clases	Lemaître et al. (2017)

Nota. Todas las librerías son de código abierto y descarga gratuita. Para instalar: pip install pandas numpy matplotlib seaborn scikit-learn scipy imbalanced-learn. Elaboración propia.

Anexo E — Descripción del Dataset AI4I 2020

Variable	Tipo	Rango (dataset completo)	Descripción
UDI	Integer	1 – 10,000	Identificador único de registro
Product ID	String	L/M/H + número	Código de identificación del producto
Type	Categórica	L, M, H	Calidad del producto: L=Baja, M=Media, H=Alta
Air temperature [K]	Float	295.3 – 304.5 K	Temperatura del ambiente del equipo
Process temperature [K]	Float	305.7 – 313.8 K	Temperatura interna del proceso
Rotational speed [rpm]	Integer	1,168 – 2,886 rpm	Velocidad de rotación del eje
Torque [Nm]	Float	3.8 – 76.6 Nm	Torque aplicado al proceso
Tool wear [min]	Integer	0 – 253 min	Desgaste acumulado de la herramienta
Machine failure	Integer	0 = Normal / 1 = Falla	Variable objetivo binaria
TWF	Integer	0 / 1	Falla por desgaste de herramienta (46 casos)
HDF	Integer	0 / 1	Falla por disipación de calor (115 casos)
PWF	Integer	0 / 1	Falla por exceso de potencia (95 casos)
OSF	Integer	0 / 1	Falla por sobrecarga (98 casos)
RNF	Integer	0 / 1	Falla aleatoria (19 casos)

Nota. Fuente: Matzka, S. (2020). AI4I 2020 Predictive Maintenance Dataset. UCI Machine Learning Repository. <https://doi.org/10.24432/C5HS5C> — Licencia: CC BY 4.0. Total registros: 10,000. Total variables: 14. Tasa de falla global: 3.39% (339 casos).